

Visión por Computador

Bootcamp

Juan Carlos Arbeláez
jarbel16@efit.edu.co
Of. 19-502



Visión por Computador

Habilitar a los computadores de adquirir, procesar, analizar y comprender información visual del mundo

Resolución de problemas

Percepción

Interacción Social

Creatividad

Planeación


Toma de decisiones

Aprendizaje y adaptación

Autonomía

Lenguaje natural

Razonamiento



Resolución de problemas

Percepción

Interacción Social

Creatividad

Planeación

Toma de decisiones

Aprendizaje y adaptación

Autonomía

Lenguaje natural

Razonamiento

Visión por Computador

Resolución de problemas

Percepción

Interacción Social

Creatividad

Planeación

Toma de decisiones

Aprendizaje y adaptación

Autonomía

Lenguaje natural

Razonamiento

Visión por Computador

Resolución de problemas

Percepción

Interacción Social

Creatividad

Planeación

Toma de decisiones

Aprendizaje y adaptación

Autonomía

Lenguaje natural

Razonamiento

Visión por Computador

Percepción Visual


No sólo trata de reproducir la percepción visual humana, sino que pretende ampliarla



Formación de imágenes

Propagación de la luz

1. La luz es emitida por una o varias fuentes luminosas
2. Interactúa con la superficie de un objeto
3. Interacción depende de:
 - a. Geometría
 - b. Propiedades electromagnéticas del objeto
 - c. La longitud de onda de la luz
4. Una parte de esta luz se dirige hacia el observador



Formación de imágenes

Color en los humanos


Tres tipos diferentes de fotorreceptores llamados conos sensibles a distintas longitudes de onda de la luz

Conos S: longitud de onda corta

Conos M: longitud de onda media

Conos L: longitud de onda larga

El ojo humano responde de forma diferente a las distintas longitudes de onda de la luz.






Aplicaciones

El espectro EM se divide en
bandas separadas, con diferentes
nombres y propiedades

Aplicaciones




Rayos Gamma




EE

Aplicaciones





Rayos Gamma




Rayos X

Aplicaciones




Ultravioleta


Aplicaciones



Ultravioleta



EE



Visible

ROBÓTICA


Aplicaciones



Visible
CGI




EE



Microondas

Imágenes


Imagen mapa de bits




Pixel of an RGB image are formed from the corresponding pixel of the three component images

Imágenes


Imagen mapa de bits




RGB




Píxeles vs Información



Datos numéricos
Bajo nivel de abstracción



¿Cómo?



Descripción
Alto nivel de abstracción

¿Qué?

Sujeto principal: Un gato doméstico de pelaje corto, predominantemente blanco con manchas negras.

Rostro y expresión: El gato está mirando hacia la derecha de la imagen con una expresión muy atenta y curiosa.



Ojos: Los ojos son uno de los elementos más llamativos: Color amarillo verdoso intenso

Pelaje: El hocico, cuello y parte inferior del rostro son blancos. La parte superior de la cabeza y alrededor de los ojos tiene manchas negras.

Nariz y bigotes: Nariz rosada clara. Bigotes largos y blancos, bien iluminados y visibles sobre el fondo cálido.


¿Qué? Representación de Imágenes

- Representar o describir una imagen
- Alto nivel conceptual
- De forma numérico
- Tenga relación con el “mundo”




¿Cómo?

Modelo Aprendizaje de Máquinas




¿Cómo?

Modelo Aprendizaje de Máquinas




Patrón de activación de una capa causa una patrón específico en la siguiente

Capas de abstracción




Incremento progresivo de abstracción

Comportamiento Red Neuronal




Estructura de Red Neuronal

Ajustar los pesos en
el proceso de
entrenamiento




ResNet50




Ejemplo de arquitectura de modelo de visión ResNet50

Etapas de Modelos




1. Entrenamiento



2. Uso

Entrenamiento


Predicción y propagación
hacia atrás del error



Ajuste

Cada uno de los pesos se ajusta proporcionalmente a cuanto contribuyeron al error

Proceso se repite mejorando progresivamente las respuestas del modelo








Diseño de modelo

- **La arquitectura de un modelo** son las operaciones internas que realiza para obtener una predicción deseada
- Características de diseño: Tamaño, número y tipo de capas, normalización, funciones de activación...
- Cada operación está definida en una capa dentro del modelo


Red Neuronal



Patrón de activación de una capa causa una patrón específico en la siguiente





Qué deberíamos hacer si en una Red Neuronal quisiéramos encontrar el mismo patrón en diferentes partes de la imagen?



Convolución

Correlación 2D


El valor de un píxel de salida se determina como una suma ponderada de los valores de los píxeles de entrada



CNN

Red Neuronal Convolutacional


- Es un tipo de arquitectura de Aprendizaje de Máquinas que usa las convoluciones como base
- Bloques consecutivos de convoluciones son usados para extraer características de una imagen
- Estos bloques de convoluciones son llamados comúnmente “extractores de características”



“The Task” *T*

La tarea qué debe resolver o hacer el modelo con una muestra

Una muestra u observación (sample) es una colección de características que se han medido cuantitativamente de algún objeto o evento



Ejemplo de tarea en IA

Seguimiento de objetos

Ejemplo tareas en visión artificial



Segmentación

Ejemplo tareas en visión artificial




Estimación de pose


Ejemplo tareas en visión artificial





Modelos Multimodales



Modelo de Visión-Lenguaje (VLM)




Aprendizaje de Representaciones




0.3	Sujeto principal
0.78	Rostro y expresión
0.56	Ojos
0.9	Pelaje
0.11	Nariz y bigotes
0.49	Orejas
0.40	Composición fotográfica
0.97	Fondo
0.24	Iluminación
0.56	Estilo visual


El gato blanco de manchas negras está mirando hacia la derecha con una expresión muy atenta y curiosa. Su postura transmite calma y concentración, como si estuviera observando algo fuera de cuadro.



0.3	Sujeto principal
0.78	Rostro y expresión
0.56	Ojos
0.9	Pelaje
0.11	Nariz y bigotes
0.49	Orejas
0.40	Composición fotográfica
0.97	Fondo
0.24	Iluminación
0.56	Estilo visual



El gato blanco de manchas negras ...



CLIP

Contrastive Language- Image Pre-training

- Modelo multimodal que combina visión y lenguaje
- Publicado por *OpenAI* en *Learning Transferable Visual Models From Natural Language Supervision* (2021)
- Capaz de realizar transferencia *zero-shot* en aplicaciones *downstream*





CLIP

Aprender la percepción desde la supervisión del lenguaje natural

1. Conjunto de datos
2. Aprendizaje contrastivo
3. Arquitectura

CLIP

Conjunto de datos

Dataset de 400 million pares de (imagen, texto) de fuentes públicas. Proceso:

- Muestrear “queries” de una lista predefinida (500K “queries”) y buscar en internet
- Extraer pares de imagen y texto de esas páginas
- Filtrar basado en heurísticos (excluir textos muy cortos, imágenes corruptas, código,...)



The man at bat readies to swing at the pitch while the umpire looks on.




A large bus sitting next to a very tall building.



A horse carrying a large load of hay and two people sitting on it.



Bunk bed with a narrow shelf sitting underneath it.



CLIP


Arquitectura

- Encoder separados para imágenes (ResNet50 o ViT) y textos (Transformer)
- Los tokens del texto son normalizados y linealmente proyectados en el espacio embebido
- Comparten un espacio latente de los embebidos

CLIP

Codificación de texto

- Cada palabra es subdividida en unidades más pequeñas - *tokens* (BPE algoritmo)
- A cada *token* se le asigna un índice que apunta a un vector
- El vector es aprendido durante el entrenamiento (embebido)




Positional Encoding Matrix for the sequence 'I am a robot'

CLIP

Aprendizaje contrastivo

- Predecir qué texto está emparejado con cuál imagen
- Se entrena conjuntamente los encoders (texto e imagen)
- Maximizar la similitud coseno de pares de embebidos (texto-imagen) correctos y minimizar los incorrectos



Distancia de Coseno

Es el coseno del ángulo entre los vectores


$$\cos(\theta) = \frac{A \cdot B}{|A| |B|}$$

La similitud coseno siempre pertenece al intervalo $[-1,1]$:


1: Vectores en la misma dirección

0: Vectores ortogonales

-1: Vectores opuestos




Contrastive Loss



$$-\log \left(\frac{\exp(\text{sim}(x_i, x_j)/t)}{\sum_{k=1, k \neq i}^{2N} \exp(\text{sim}(x_i, x_k)/t)} \right)$$

Compare to every other sample within this particular batch, including

x_i, x_j except: x_i, x_i




$$\text{sim}(z_i, z_j) = \frac{z_i \cdot z_j}{\|z_i\| \cdot \|z_j\|}$$

CLIP

Aprendizaje contrastivo

Elementos de la función de costo:

1. Par correspondiente de embebidos de texto e imágenes (I_i, T_i)
2. Similitud coseno entre los embebidos
3. Optimización del cross-entropy simétrico (fila ℓ_i^{img} y columna ℓ_i^{text}) del softmax de las similitudes



$$\mathcal{L} = \frac{1}{2N} \sum_{i=1}^N \left[\ell_i^{\text{img}} + \ell_i^{\text{text}} \right]$$

Cross-entropy por fila:

$$\ell_i^{\text{img}} = -\log \frac{\exp(\text{sim}(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(I_i, T_j)/\tau)}$$

Cross-entropy por columna:

$$\ell_i^{\text{text}} = -\log \frac{\exp(\text{sim}(T_i, I_i)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(T_i, I_j)/\tau)}$$


CLIP

Usos comunes


Puede ser usado como:

1. Extractor de características
2. *Zero-shot* con ingeniería de *prompts*
3. Usar los embebidos para sistemas de *image retrieval*


(2) Create dataset classifier from label text




Píxeles vs Información



Datos numéricos
Bajo nivel de abstracción



¿Cómo?



Descripción
Alto nivel de abstracción

¿Qué?

Sujeto principal: Un gato doméstico de pelaje corto, predominantemente blanco con manchas negras.

Rostro y expresión: El gato está mirando hacia la derecha de la imagen con una expresión muy atenta y curiosa.

Ojos: Los ojos son uno de los elementos más llamativos: Color amarillo verdoso intenso

Pelaje: El hocico, cuello y parte inferior del rostro son blancos. La parte superior de la cabeza y alrededor de los ojos tiene manchas negras.

Nariz y bigotes: Nariz rosada clara. Bigotes largos y blancos, bien iluminados y visibles sobre el fondo cálido.