

Búsqueda Semántica Multimodal con CLIP

Embeddings · Retrieval · Frontier AI

¿Cómo busca una máquina?

El problema de la búsqueda semántica

Búsqueda por palabras clave

- Busca coincidencias exactas de texto
- "perro" ≠ "dog" ≠ "canino"
- No entiende imágenes
- Frágil ante sinónimos



Búsqueda semántica

- Entiende el significado, no las palabras
- "dog" ≈ "perro" ≈ imagen de perro
- Funciona entre texto e imagen
- Robusta a paráfrasis y variaciones

Píxeles vs Representación

De datos crudos a significado

Imagen original (miniatura)




Zoom

Fragmento ampliado (cuadrícula de píxeles con valores RGB)

[255, 215, 150]	[255, 206, 130]	[255, 198, 120]	[250, 185, 105]	[280, 185, 95]	[245, 170, 90]	[235, 150, 70]	[220, 130, 60]	[200, 110, 50]	[180, 90, 40]	[160, 75, 35]
[255, 220, 160]	[255, 212, 140]	[255, 203, 125]	[255, 189, 110]	[248, 174, 95]	[238, 153, 72]	[225, 133, 62]	[225, 113, 52]	[205, 93, 42]	[185, 78, 36]	[165, 62, 30]
[255, 225, 170]	[255, 218, 150]	[255, 213, 135]	[255, 194, 115]	[250, 179, 100]	[240, 158, 75]	[230, 138, 65]	[210, 118, 55]	[190, 98, 45]	[170, 82, 38]	[170, 65, 30]
[255, 228, 175]	[255, 221, 155]	[255, 213, 140]	[255, 200, 120]	[253, 185, 105]	[243, 165, 80]	[233, 145, 70]	[215, 125, 60]	[195, 105, 48]	[175, 88, 40]	[175, 70, 30]
[255, 230, 180]	[255, 224, 160]	[255, 218, 145]	[255, 206, 128]	[255, 192, 112]	[245, 172, 86]	[235, 152, 74]	[220, 132, 62]	[220, 112, 52]	[180, 95, 42]	[180, 75, 35]
[250, 210, 160]	[245, 200, 150]	[240, 190, 140]	[235, 180, 130]	[220, 165, 110]	[195, 140, 85]	[150, 110, 65]	[100, 75, 45]	[70, 50, 30]	[60, 45, 28]	[60, 45, 28]
[220, 180, 130]	[210, 165, 120]	[200, 150, 110]	[180, 130, 90]	[140, 100, 70]	[80, 60, 45]	[35, 30, 25]	[20, 18, 18]	[25, 20, 15]	[35, 25, 20]	[40, 30, 25]
[200, 160, 115]	[190, 145, 105]	[170, 125, 85]	[130, 90, 60]	[70, 50, 35]	[25, 20, 18]	[15, 14, 14]	[15, 14, 14]	[18, 16, 16]	[28, 22, 22]	[50, 45, 35]
[190, 140, 100]	[170, 120, 85]	[140, 90, 60]	[80, 50, 35]	[40, 25, 20]	[30, 15, 16]	[30, 15, 16]	[40, 25, 22]	[80, 50, 45]	[120, 70, 70]	[150, 110, 95]
[180, 130, 95]	[150, 100, 70]	[100, 60, 45]	[60, 30, 25]	[50, 20, 18]	[80, 40, 40]	[150, 80, 90]	[200, 130, 130]	[200, 130, 130]	[220, 160, 160]	[210, 160, 170]
[150, 170, 90]	[130, 160, 80]	[110, 150, 70]	[90, 140, 60]	[70, 130, 50]	[60, 120, 45]	[80, 130, 60]	[110, 130, 60]	[140, 150, 100]	[140, 170, 100]	[160, 180, 110]

Vector de embedding (512 dimensiones)

0.32	-0.18	0.71	0.05	-0.47	0.23	-0.12	0.88	0.31	-0.34	...	0.27	-0.15	0.61	$\mathbb{R}^{512}$
primeros elementos (ejemplos)										últimos elementos (ejemplos)				



Millones de números sin contexto

Un punto en el espacio del significado


Embeddings

Representar el mundo como vectores

Un **embedding** es una función que convierte cualquier objeto

— texto, imagen, audio — en un vector de números reales en un espacio de alta dimensión.

- Objetos similares → vectores cercanos
- Objetos diferentes → vectores lejanos
- Las operaciones aritméticas tienen sentido semántico
- CLIP usa 512 dimensiones para imagen y texto



Similitud coseno


La distancia que importa

$$\text{sim}(a, b) = (a \cdot b) / (\|a\| \cdot \|b\|) \in [-1, 1]$$

≈ 1

Similar


Mismo ángulo
mismo significado



≈ 0

Sin relación


Ángulo de 90°
significados distintos



≈ -1

Opuesto

Ángulo de 180°
significados contrarios




Normalización L2

Por qué el producto punto es suficiente

Si normalizamos todos los vectores ($\|v\| = 1$),
entonces:

$$\text{sim}(a, b) = a \cdot b$$


Una multiplicación matricial recupera todos los
scores del corpus.



Buscar en un corpus de 2 000 imágenes toma menos de 1 ms.


El espacio compartido de CLIP

Texto e imagen en la misma geometría



¿Funciona el espacio compartido?

Pares correctos vs pares aleatorios



Media correctos

~0.28

Media aleatorios

~0.15


Gap

+0.13

El gap positivo confirma que la señal existe — la búsqueda semántica es posible.

El pipeline de búsqueda

Indexar $\rightarrow$ query $\rightarrow$ scores $\rightarrow$ top-k



Costo de indexación: se paga una vez. **Costo de búsqueda:** milisegundos, sin importar el corpus.

Un solo pipeline, dos modalidades

El espacio compartido hace el trabajo

Texto → Imagen

```
"a cyclist jumping" → get_text_embeddings() → compute_scores() → top-k
```

Imagen → Imagen


```
[imagen query] → get_image_embeddings() → compute_scores() → top-k
```

Mismo código. Distinto encoder. Esto es lo que hace especial el espacio compartido.

La matriz de similitud

$$S = I \cdot T^T \in \mathbb{R}^{N \times N}$$

Heatmap 15×15 escala RdYlGn



- $S[i,j]$ = similitud entre imagen i y texto j
- Diagonal $S[i,i]$ = par correcto
- Fuera diagonal = pares aleatorios
- Diagonal brillante confirma alineación
- Esto es exactamente lo que optimiza CLIP durante entrenamiento

Cuándo falla CLIP

Límites sistemáticos del modelo

Negaciones

"a street with no cars"

CLIP no modela ausencias — entiende "cars", ignora "no"

Conteo exacto

"exactly three people"

El modelo no cuenta, percibe presencia temática

Relaciones espaciales

"a dog to the left of a cat"

No razona sobre posiciones relativas entre objetos


Atributos compuestos

"a red ball next to a blue box"

Mezcla atributos sin anclarlos a objetos específicos

El modality gap

Por qué texto e imagen no se mezclan en 2D



¿Qué es?

Los embeddings de imagen y texto ocupan regiones distintas de la hiperesfera, aunque sean semánticamente similares.

¿Por qué no es un bug?

El histograma lo confirma: el gap entre pares correctos y aleatorios existe en las 512 dimensiones reales. La proyección 2D engaña.


Referencia: *Liang et al., 2022 — Mind the Gap*

De retrieval a Frontier AI

El mismo mecanismo, a mayor escala

RAG — Retrieval Augmented Generation

Los LLMs no lo saben todo; el retrieval llena el gap



- El modelo de lenguaje no 'recuerda' — recupera en tiempo de inferencia
- La base de conocimiento se actualiza sin reentrenar el modelo
- ChatGPT con búsqueda, Perplexity, Copilot — todos usan RAG
- La calidad del retrieval determina la calidad de la respuesta

RAG Multimodal

Cuando la memoria incluye imágenes

RAG textual

- Corpus: documentos de texto
- Query: texto
- Embedding: solo lenguaje
- Ejemplo: Q&A sobre PDFs




RAG multimodal

- Corpus: imágenes + texto + video
- Query: texto, imagen o ambos
- Embedding: espacio compartido (CLIP)
- Ejemplo: Google Lens, GPT-4o

Los modelos frontier usan esto

La cadena de ideas desde CLIP



- DALL-E 2 invierte el proceso: texto → embedding CLIP → imagen
- GPT-4o tiene encoder de visión alineado con el LLM — exactamente como CLIP
- Gemini y Claude nacieron multimodales: el espacio compartido es nativo
- Todos comparten la misma idea: alinear espacios de representación

Alineamiento de espacios de representación


La idea unificadora de la IA moderna

La pregunta central de la IA moderna no es
'¿cómo clasifico esto?' sino

**'¿cómo represento esto de forma que sea
útil para cualquier tarea?'**

CLIP respondió esa pregunta para imagen y texto en
2021.

Los modelos frontier la están respondiendo para todas
las modalidades.



Búsqueda híbrida

Combinar texto e imagen como señal

$$\text{score}(i) = \alpha \cdot \text{sim_texto}(i) + (1-\alpha) \cdot \text{sim_imagen}(i)$$

$$\alpha = 1.0$$

Texto puro — baseline

$$\alpha = 0.0$$

Imagen pura — mismo resultado para todos

$$\alpha \in (0,1)$$

Híbrido — la imagen actúa como prior temático

Esto es lo que construirán en el notebook 03 — y lo que evaluará el leaderboard.

Ahora lo construyen ustedes

01_clip_baseline → 02_image_retrieval → 03_competition

Corpus: 2000 imágenes de Flickr30k

Métrica: Overlap@10 contra oracle de captions reales

Lo que diferencia a los equipos: la calidad del query que inventan